AI
ENGINEERING
AI-Powered products

MÓDULO 3: Data-driven AI

Sesión 6: Fundamentos de data driven AI - Análisis, formateo y normalización de datos existentes

Mentor: Juan Pablo Mesa López
LIDR.co, training the Tech Leaders' of the future

L1DR

Data-driven AI

La metodología que pone tus datos en el centro de cada decisión de IA

Tus datos
Contexto real de tu negocio

+

Privacidad
Tus datos nunca salen de tu control

+

IA
RAG + orquestación de agentes

=

Ventaja competitiva
Sistemas de IA que razonan exclusivamente sobre tu información privada

No es conectar un chatbot a ChatGPT · es construir tu propio ecosistema de IA

L1DR

Cada problema de la IA genérica, una pieza que lo resuelve hoy

Problema de la IA genérica	Pieza que construimos hoy
Respuestas con datos públicos, no con tu contexto	Catálogo de fuentes + ingesta de tu corpus real
Riesgo de filtración de información confidencial	Pseudonimización con Presidio + mapping table
Alucinaciones sin posibilidad de verificación	Document canónico con metadata trazable a la fuente
Dependencia de proveedores externos	Todo el código en tu servicio IA · soberanía
Imposibilidad de auditar las respuestas	Catálogo versionado en git + política reparar/cuarentena

Lo que vendes en tu web · lo que construimos en las próximas dos horas

L1DR

RAG vs Fine-tuning · cinco dimensiones

Por qué fine-tuning no es alternativa, es capa ortogonal

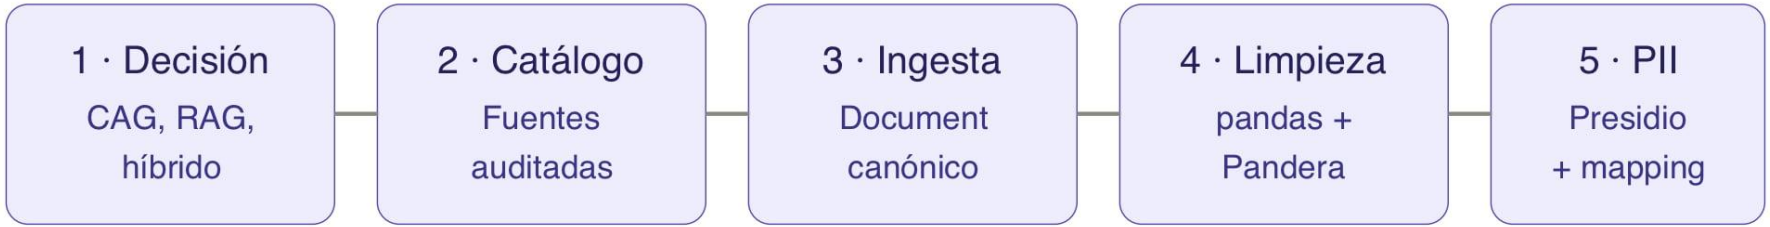
Dimensión	RAG	Fine-tuning
Actualización	Instantánea	Reentrenamiento
Coste	Bajo y predecible	Alto y variable
Trazabilidad	Fuente citada	No disponible
Alucinaciones	Minimizadas	Frecuentes
Privacidad	Control total	Datos en modelo

RAG es base de conocimiento dinámica · fine-tuning modifica el modelo

Cuando añades un documento nuevo, RAG lo integra al instante

L1DR

El viaje del dato, cinco piezas



Todo en Python en el servicio IA · Rails solo como cliente HTTP

Hoy preparamos el corpus para que merezca ser vectorizado

El primer embedding es Sesión 7

L1DR

Las cuatro restricciones del CAG

Las cuatro tienen que estar en verde a la vez · AND, no OR

1 · Context window

¿Cabe el corpus completo
en la ventana del modelo?

2 · Coste

¿El coste/turno con prefix
caching es asumible?

3 · Latencia

¿Se queda bajo SLO con
el corpus entero en contexto?

4 · Lost-in-the-middle

¿El modelo realmente usa
el centro del contexto?

L1DR

El árbol sobre cuatro ejes

Cada eje en rojo cuenta · uno solo basta para forzar RAG

Volumen

Tokens del corpus vs ventana útil del modelo (70% segura)

Frecuencia

Días entre refrescos
¿Compatible con prefix caching?

Trazabilidad

¿Hay que citar la fuente de cada afirmación?

Control de acceso

¿Cada usuario ve solo sus propios datos?

Fine-tuning no está aquí · es capa ortogonal, no alternativa

L1DR

Antipatrón: vectorizar primero, mirar después

Tres modos de fallo, los tres plantados en nuestro corpus de demo

1 · Mezcla de versiones

BUDGET-2024-0005 v1 (30.000 €) y v2 (32.000 €) coexisten · el retriever devuelve ambos

2 · Fuentes podridas

rate_card_2024.xlsx, last_modified 12/01/2024 · indexarlo = tarifas de hace año y medio

3 · Gaps invisibles

transcripcion_2023-09-08_legacy.txt sin speaker tags · el parser produce basura sin avisar

L1DR

Tres capas, responsabilidades separadas

Loader

Produce bytes · no mira dentro · hoy filesystem, mañana HTTP, S3, BD

Parser

Bytes → Documents · lo único que entiende el formato · uno por familia

Normalizer

Reglas de negocio sobre Documents canónicos · es cleaning/ + pii/ del 2.4 y 2.5

El Document canónico es el contrato downstream

Modelo plano · extra para lo específico de cada formato

L1DR

Offline vs online · la separación del Article 1

Pipeline offline

Indexación · hoy lo construimos

POST /ingestion/runs → 202

Background task · minutos OK

GET /ingestion/jobs/{id}

El cliente hace polling

Pipeline online

Query · Sesión 7

POST /query → 200

Síncrono · bajo SLO < 3 s

El usuario espera

No bloquear nunca

Indexar un corpus tarda minutos · llamada síncrona = cliente tirado

Por eso indexación es 202 + polling, query será 200 directo

L1DR

Cuatro familias de suciedad · plantadas en el seed

1 · Heterogeneidad

currency: "EUR" vs "eur"

en 0001 vs 0002

→ se repara en limpieza

2 · Disguised nulls

client_name: "TBD"

en 0003

→ va a cuarentena

3 · Duplicados divergentes

BUDGET-2024-0005 v1: 30.000

BUDGET-2024-0005 v2: 32.000

→ keep last by signed_at

4 · Out-of-range

total_amount: -50000

en 0004

→ descarte (Check.ge(0))

6 ficheros → limpieza → 5 filas → validación → 3 valid + 1 cuarentena + 1 descarte

L1DR

Tres modos de filtración semántica vía RAG

El control de acceso del backend no protege contra ninguno · defender antes del embedding

1 · Directa

El nombre/email/id aparece literal en la respuesta · pseudonimizamos antes de embedder

2 · Por agregación

CP + edad + género reidentifican aunque cada campo sea inocuo · pseudonimizar cuasi-ids

3 · Por inferencia · la más peligrosa

El modelo adivina desde el lenguaje · pseudonimizar no la frena · queda abierta como teoría

✋Tiempo para el feedback con ROTI

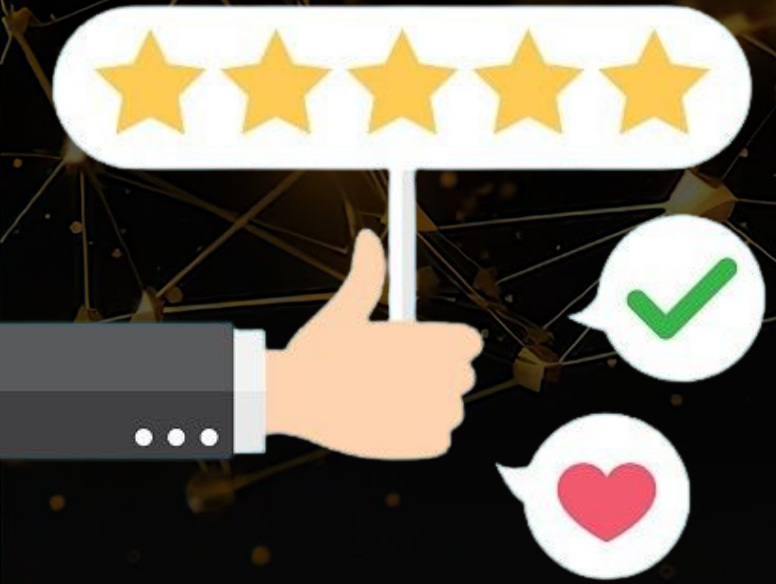
¿Cuánto valor te ha agregado esta sesión?



Absolutamente nada	Poco	Suficiente	Bastante	Más de lo que esperaba

LIDR

ROTI



¡GRACIAS!

LIDR.co, AI-Powered Careers

@lidr_ai

#followtheLIDR